
Interpolation entre mesures de probabilités

sujet proposé par Pierre Monmarché

`pierre.monmarche@univ-eiffel.fr`

$$\frac{1}{3} \text{ } \text{apple} + \frac{2}{3} \text{ } \text{orange} = ?$$

La question à laquelle ce projet s'intéresse est la suivante : existe-t-il une définition naturelle d'interpolation entre deux mesures de probabilités, qui permettrait de passer continûment de l'une à l'autre ? Ou, étant donnée une famille de mesures de probabilités, que serait un barycentre représentatif ?

1 Interpolation(s) entre deux mesures de probabilités

On se donne deux mesures de probabilités μ_0 et μ_1 sur $\mathbb{R}$, et des variables aléatoires indépendantes $X_0 \sim \mu_0$, $X_1 \sim \mu_1$. Considérons une première façon d'interpoler de μ_0 à μ_1 : pour $t \in [0, 1]$, on pose simplement

$$X_t = (1 - t)X_0 + tX_1, \tag{7.1}$$

et on note μ_t la loi de X_t .

T1. Supposons dans cette question que μ_0 et μ_1 admettent des densités f_0 et f_1 par rapport à la mesure de Lebesgue. Déterminer la densité f_t de μ_t .

S1. Représentez f_t pour $t \in \{0, 1/3, 1/2, 2/3, 1\}$ dans les trois cas suivants :

1. $\mu_0 = \mathcal{U}([0, 1])$ et $\mu_1 = \mathcal{N}(0, 1)$.
2. $\mu_0 = \mathcal{U}([0, 1])$ et $\mu_1 = \mathcal{U}([-1, 1])$.
3. $\mu_0 = \mathcal{N}(0, 0.5)$ et $\mu_1 = \mathcal{N}(2, 2)$.

On pourra éventuellement également représenter la fonction $(x, t) \mapsto f_t(x)$ sous forme de heatmap ou de surface, pour $t \in [0, 1]$.

T2. Parmi les trois familles de mesures de probabilités ci-dessous, déterminer celles qui sont préservées par l'opération d'interpolation précédente (autrement dit : si μ_0 et μ_1 sont toutes les deux dans la famille, est-ce le cas de μ_t pour tout $t \in [0, 1]$?) :

- Les mesures de Dirac : $\mathcal{M}_D = \{\delta_x, x \in \mathbb{R}\}$.
- Les mesures uniformes sur des intervalles : $\mathcal{M}_U = \{\mathcal{U}([a, b]), a, b \in \mathbb{R}, a < b\}$
- Les mesures gaussiennes : $\mathcal{M}_G = \{\mathcal{N}(m, \sigma^2), m \in \mathbb{R}, \sigma^2 > 0\}$.

Considérons maintenant une seconde façon naturelle d'interpoler, qui consiste simplement à poser $\eta_t = (1 - t)\mu_0 + t\mu_1$ pour $t \in [0, 1]$.

T3. Pour des variables indépendantes $U \sim \mathcal{U}([0, 1])$, $X_0 \sim \mu_0$ et $X_1 \sim \mu_1$, on pose

$$Y_t = 1_{\{U > t\}}X_0 + 1_{\{U \leq t\}}X_1. \quad (7.2)$$

Montrer que $Y_t \sim \eta_t$ pour $t \in [0, 1]$.

S2. Même question que **S1** mais pour η_t au lieu de μ_t .

T4. Même question que **T2** mais pour η_t au lieu de μ_t .

Introduisons maintenant une troisième interpolation, qui consiste à poser, pour $U \sim \mathcal{U}([0, 1])$,

$$Z_t = (1 - t)F_0^{-1}(U) + tF_1^{-1}(U), \quad (7.3)$$

où F_i est la fonction de répartition de μ_i pour $i \in \{0, 1\}$. On note ν_t la loi de Z_t .

S3. Même question que **S1** mais pour ν_t au lieu de μ_t , et au lieu de tracer la densité on représentera plutôt des histogrammes de variables indépendantes de loi ν_t .

T5. Même question que **T2** mais pour ν_t au lieu de μ_t (dans le cas gaussien, on pourra exprimer l'inverse de la fonction de répartition de $\mathcal{N}(m, \sigma^2)$ en fonction de celle de $\mathcal{N}(0, 1)$).

T6. Pour les trois notions d'interpolations introduites, les propriétés suivantes sont-elles vérifiées ?

1. L'espérance de l'interpolation est l'interpolation des espérances, $(1 - t)\mathbb{E}(X_0) + t\mathbb{E}(X_1)$.
2. Si $\mu_0 = \mu_1$ alors l'interpolation est constante égale à μ_0 .
3. L'interpolation est continue : si $s \rightarrow t$, $\mu_s \rightarrow \mu_t$ pour la convergence en loi (idem pour η_t et ν_t).

S4. Jusqu'ici on a regardé les constructions précédentes comme des familles de lois, indexée par $t \in [0, 1]$, allant de μ_0 à μ_1 (à savoir, $(\mu_t)_{t \in [0,1]}$, $(\eta_t)_{t \in [0,1]}$ ou $(\nu_t)_{t \in [0,1]}$ selon la construction). Mais on peut aussi considérer qu'on a construit des familles de variables aléatoires, à savoir $(X_t)_{t \in [0,1]}$, $(Y_t)_{t \in [0,1]}$ et $(Z_t)_{t \in [0,1]}$, telles que définies par (7.1), (7.2) et (7.3). Dans cette question, le but est de comprendre à quoi ressemblent les trajectoires de ces variables aléatoires (on peut penser à X_t , Y_t ou Z_t comme la position d'une particule au temps t ; avec les trois constructions, la particule est initialement distribuée selon μ_0 au temps 0 et finalement selon μ_1 au temps 1, mais la façon dont elle se déplace entre ces deux situations n'est pas la même selon les trois constructions). Pour représenter ceci, pour chaque méthode d'interpolation, simuler $n = 10$ réalisations indépendantes des trajectoires des variables aléatoires et tracez les en fonction du temps (en mettant les 10 trajectoires sur le même graphe).

T7. Parmi $(X_t)_{t \in [0,1]}$, $(Y_t)_{t \in [0,1]}$ et $(Z_t)_{t \in [0,1]}$, quelles trajectoires sont presque sûrement continues ?

2 Distance de Wasserstein

Pour deux mesures de probabilités μ_0 et μ_1 sur $\mathbb{R}$, de fonctions de répartition F_0 et F_1 , et pour $p \geq 1$, on pose

$$\mathcal{W}_p(\mu_0, \mu_1) = \left(\int_0^1 |F_0^{-1}(u) - F_1^{-1}(u)|^p du \right)^{1/p},$$

qu'on appelle la distance de Wasserstein L^p entre μ_0 et μ_1 . On note $\mathcal{P}_p(\mathbb{R})$ les mesures de probabilités sur $\mathbb{R}$ ayant un moment d'ordre p fini (c'est-à-dire telles que $\mu \in \mathcal{P}_p(\mathbb{R})$ si $\mathbb{E}_\mu(|X|^p) < \infty$).

T8. Montrer que $\mathcal{W}_p(\mu_0, \mu_1) < \infty$ si $\mu_0, \mu_1 \in \mathcal{P}_p(\mathbb{R})$, et que $\mathcal{W}_p$ définit sur $\mathcal{P}_p(\mathbb{R})$ une distance.

T9. On considère μ et une suite $(\mu_n)_{n \in \mathbb{N}}$ dans $\mathcal{P}_p(\mathbb{R})$. On suppose que $\mathcal{W}_p(\mu, \mu_n) \rightarrow 0$ quand $n \rightarrow \infty$. Montrer que $(\mu_n)_{n \in \mathbb{N}}$ converge vers μ au sens de la convergence en loi (on pourra commencer par trouver des variables aléatoires $X \sim \mu$ et $X_n \sim \mu_n$ telles que $\mathcal{W}_p^p(\mu, \mu_n) = \mathbb{E}(|X - X_n|^p)$).

T10. Étant donnés $N \in \mathbb{N}^*$, $(x_i)_{1 \leq i \leq N}$ et $(y_i)_{1 \leq i \leq N}$, on considère $\mu_0 = \frac{1}{N} \sum_{i=1}^N \delta_{x_i}$ et $\mu_1 = \frac{1}{N} \sum_{i=1}^N \delta_{y_i}$. Montrer que

$$\mathcal{W}_p^p(\mu_0, \mu_1) = \frac{1}{N} \sum_{i=1}^N |x_{(i)} - y_{(i)}|^p, \quad (7.4)$$

où $(x_{(i)})_{1 \leq i \leq N}$ désigne les x_i triés dans l'ordre croissant ($x_{(1)} \leq \dots \leq x_{(N)}$), et de même pour les $y_{(i)}$.

S5. On propose la façon suivante d'estimer $\mathcal{W}_p(\mu_0, \mu_1)$ quand F_0^{-1} et F_1^{-1} ne sont pas accessibles: on génère $(X_i)_{1 \leq i \leq N}$ i.i.d. de loi μ_0 et $(Y_i)_{1 \leq i \leq N}$ i.i.d. de loi μ_1 , on pose

$$\mu_0^{(N)} = \frac{1}{N} \sum_{i=1}^N \delta_{X_i} \quad \mu_1^{(N)} = \frac{1}{N} \sum_{i=1}^N \delta_{Y_i}$$

et on approche $\mathcal{W}_p(\mu_0, \mu_1)$ par $\mathcal{W}_p(\mu_0^{(N)}, \mu_1^{(N)})$. Mettez en œuvre cette méthode pour $\mu_0 = \mathcal{N}(0, 1)$ et $\mu_1 = \mathcal{N}(1, 1)$ et $p = 2$ (on fera varier N et on représentera $N \mapsto \mathcal{W}_2(\mu_0^{(N)}, \mu_1^{(N)})$, et on calculera la valeur théorique de $\mathcal{W}_2(\mu_0, \mu_1)$, qui est explicite pour ces μ_0, μ_1).

On dit qu'une courbe $(m_t)_{t \in [0,1]}$ à valeur dans $\mathcal{P}_p(\mathbb{R})$ est une géodésique pour $\mathcal{W}_p$ si, pour tout $t, s \in [0, 1]$,

$$\mathcal{W}_p(m_t, m_s) = |t - s| \mathcal{W}_p(m_0, m_1).$$

T11. Montrer que l'interpolation $(\nu_t)_{t \geq 0}$ entre deux mesures $\mu_0, \mu_1 \in \mathcal{P}_p(\mathbb{R})$, telle que définie dans la partie précédente (cf. (7.3)), reste dans $\mathcal{P}_p(\mathbb{R})$ pour tout $t \in [0, 1]$, et est une géodésique pour $\mathcal{W}_p$ (on pourra démontrer, ou admettre, que l'inverse de la fonction de répartition d'une variable de la forme $G(U)$ avec $U \sim \mathcal{U}([0, 1])$ et $G :]0, 1[\rightarrow \mathbb{R}$ croissante, continue à gauche avec limite à droite, est forcément G).

T12. Montrer que l'interpolation $(\mu_t)_{t \in [0, 1]}$ définie en (7.1) n'est en général pas une interpolation pour $\mathcal{W}_p$.

S6. Représentez $t \mapsto \mathcal{W}_2(\mu_0, \eta_t)$ quand $\mu_0 = \mathcal{N}(0, 1)$ et $\mu_1 = \mathcal{N}(1, 1)$ (en utilisant la représentation (7.2) pour η_t et la méthode de la question S5 avec un N assez grand). L'interpolation $(\eta_t)_{t \in [0, 1]}$ est-elle une géodésique pour $\mathcal{W}_2$?

3 Barycentre d'un ensemble de mesures de probabilité

T13. Étant données des variables $X_1, \dots, X_n \in L^2(\Omega, \mathbb{R})$, montrer que $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ est l'unique minimiseur de la fonction $J : L^2(\Omega, \mathbb{R}) \rightarrow \mathbb{R}$ donnée par

$$J(Y) = \sum_{i=1}^n \mathbb{E}(|X_i - Y|^2).$$

T14. Étant données $\mu_1, \dots, \mu_n \in \mathcal{P}_2(\mathbb{R})$, montrer que l'unique minimiseur de $J : \mathcal{P}_2(\mathbb{R}) \rightarrow \mathbb{R}$ donnée par

$$J(\nu) = \sum_{i=1}^n \mathcal{W}_2^2(\mu_i, \nu),$$

qu'on appelle de barycentre Wasserstein de $\mu_1, \dots, \mu_n$, est la loi de

$$Z = \frac{1}{n} \sum_{i=1}^n F_i^{-1}(U),$$

avec F_i la fonction de répartition de μ_i et $U \sim \mathcal{U}([0, 1])$.

T15. Déterminer le barycentre Wasserstein de $\mu_1, \dots, \mu_n$ quand les μ_i sont tous dans $\mathcal{M}_D$, ou tous dans $\mathcal{M}_U$, ou tous dans $\mathcal{M}_G$ (avec les notations de la question T2).

S7. Implémenter une méthode qui, pour un N donné, étant données trois familles $(x_{i,k})_{1 \leq i \leq N}$ pour $k \in \{1, 2, 3\}$, donne l'histogramme du barycentre Wasserstein de μ_1, μ_2, μ_3 avec

$$\mu_k = \frac{1}{N} \sum_{i=1}^N \delta_{x_{i,k}}.$$

Illustrer son application dans ces trois cas suivant avec $N = 1000$ (on représentera les histogrammes de chaque famille et celui du barycentre):

1. Les $x_{i,1}$ (resp. $x_{i,2}$, resp. $x_{i,3}$) sont i.i.d. de loi $\mathcal{N}(-1, 1)$ (resp. $\mathcal{N}(1, 2)$ et $\mathcal{N}(-3, 0.5)$).
2. Même chose mais avec les lois $\mathcal{U}([0, 1])$, $\mathcal{U}([0, 3])$ et $\mathcal{U}([0, 5])$
3. Même chose mais avec les lois $\mathcal{N}(0, 1)$, $\mathcal{U}([-1, 1])$ et $\mathcal{E}(1)$.